

Actividad 3 — Desafío: El Agente de Hierro

🕒 25 minutos (15 diseño + 10 puesta en común)

👥 Equipos de 3 a 5 en breakout rooms

✏️ Se diseña, NO se construye en n8n

Objetivo

Diseñar la **arquitectura completa de un agente con guardrails** para un caso de negocio real, aplicando los cuatro componentes de seguridad vistos en el módulo: herramientas de mínimo privilegio, validación determinista, Human-in-the-loop y condición de parada. El entregable es un **diagrama**, no un workflow: acá se evalúa el criterio de diseño, no el clic.

El caso: Aprobación de Facturas con Discrepancias

Una PyME recibe cada semana unas 40 facturas de proveedores por mail. El monto de cada factura debería coincidir con el contrato vigente del proveedor. Hoy una persona revisa todo a mano: la mayoría coincide, pero un 15% presenta discrepancias (aumentos no pactados, ítems duplicados, proveedores nuevos sin contrato). La empresa quiere automatizar el proceso, pero **ninguna factura puede aprobarse ni rechazarse sin control**: un error acá cuesta plata real.

Consigna paso a paso (para los equipos)

1. **Definan el objetivo del agente en una sola frase.** ¿Qué decide el agente y qué NO decide? Esa frase después sería el corazón del System Prompt.
2. **Elijan el trigger.** ¿Cómo entra la factura al sistema? (mail entrante, carpeta de Drive, webhook...)
3. **Separen lo determinista de lo ambiguo.** Marquen qué partes resuelven con nodos lineales (extraer el adjunto, parsear el monto) y en qué punto exacto entra el agente.
4. **Diseñen al menos 1 herramienta de lectura.** Nombrenla, digan qué consulta (ej.: contrato vigente del proveedor) y qué devuelve. Recuerden el mínimo privilegio: la tool no puede exponer la base completa.
5. **Definan 1 validación lógica determinista.** ¿Qué regla IF decide si hay discrepancia? (ej.: diferencia > 2% del monto contratado).
6. **Marquen el punto de aprobación humana (HITL).** ¿Qué acción queda SIEMPRE en manos de una persona, quién es esa persona y por qué canal aprueba? (Slack, mail, Airtable...)
7. **Agreguen la condición de parada.** ¿Cuántos intentos o iteraciones puede hacer el agente antes de frenar y escalar? ¿Qué pasa cuando frena?
8. **Dibujen el flujo completo** en papel, Excalidraw, Miro o FigJam, con los 4 componentes rotulados: *Tool de lectura · Validación lógica · HITL · Parada por intentos.*

9. **Elijan un vocero** que presente el diagrama en 90 segundos en la puesta en común.

Reglas del desafío

- No se construye nada en n8n: el valor está en la arquitectura y su justificación de negocio.
- Todo componente del diagrama debe poder responder "¿por qué está acá?".
- Si un equipo termina antes: ¿qué pasa si el proveedor es nuevo y no tiene contrato? Diseñen esa rama.

Entregable

Foto o captura del diagrama subida al chat de Zoom antes de la puesta en común.

Guía de feedback para la puesta en común (docente)

Check	Qué mirar
¿Lo determinista quedó fuera del agente?	Extracción y parseo deben ser nodos lineales; el agente solo entra donde hay ambigüedad ("averiguar por qué no coincide").
¿La tool es de mínimo privilegio?	Debe consultar algo acotado ("Consultar_Contrato_Proveedor"), nunca "acceso a toda la base contable".
¿El HITL está en la acción crítica?	Aprobar/rechazar el pago lo dispara un humano con un clic; el agente solo prepara y recomienda.
¿La parada tiene destino?	No alcanza con "corta a las 5 vueltas": al frenar debe escalar a una persona con el contexto de lo que intentó.